

GRADO EN INGENIERÍA INFORMÁTICA DE GESTIÓN Y
SISTEMAS DE INFORMACIÓN

TRABAJO FIN DE GRADO

LLMs y RAG para una mejor interacción con JIRA



Estudiante: Aróstegui García, Alberto

Directores: Egaña Aranguren, Mikel; López Novoa, Unai

Curso: 2023-2024

Fecha: 16 de junio de 2024

Resumen:

Este trabajo se enfoca en explorar los límites de los ensayos a tracción para probetas de materiales compuestos.

Palabras Clave: *Materiales Compuestos*

Abstract:

English

Key Words:

Laburpena:

Euskera

Gako-hitzak:

Índice

Abreviaturas	8
1 Introducción	9
2 Contexto	10
2.1 Gestión de proyectos	10
2.2 Herramientas	10
2.2.1 JIRA	10
2.2.2 Git - Gitlab	11
2.3 JiraGPT Next	11
3 Planificación	13
3.1 Tareas	13
3.1.1 Gestión y planificación	13
3.1.2 Investigación	14
3.1.3 Ideas sistemas RAG	16
3.1.4 Definición de pruebas	16
3.1.5 Documentación	17
3.2 Presupuesto	18
3.2.1 Costes de software	18
3.2.2 Costes de mano de obra	18
3.2.3 Costes de hardware	19
3.3 Gestión de riesgos	20
4 Tecnologías	22
4.1 Modelos grandes de lenguaje	22
4.2 Retrieval Augmented Generation	22
4.2.1 Funcionamiento	23
4.3 Word embeddings	23
4.4 Ontologías	24
4.5 Grafos de conocimiento	24
5 Diseño	26
5.1 Estado inicial	26
5.2 Propuestas	26
5.2.1 Ontología	27
5.2.2 Embeddings	29
5.2.3 Grafos de conocimiento	30
6 Implementación	31

6.1	Implementación de RAG: Embeddings	31
6.1.1	Extracción de datos	31
6.1.2	Interacción con el modelo	31
6.2	Implementación de RAG: Ontología	32
6.2.1	Interacción con el modelo	32
7	Ejecución de pruebas	33
7.1	Entorno de pruebas	33
7.2	Evaluación de los resultados	33
7.3	Resultados	33
8	Conclusiones	35
8.1	Objetivos	35
8.2	Conclusiones personales	35
8.3	Trabajo futuro	35
9	Anexo I	36
9.1	Conjunto de preguntas	36
	Referencias	44

Índice de figuras

1	Esquema de división del trabajo	13
2	Esquema de funcionamiento de una arquitectura RAG [9]	23
3	Diagrama de RAG con ontología	27
4	Diagrama de RAG con embeddings	29
5	Diagrama de RAG con grafos de conocimiento	30
6	Resultados para GPT-3.5-turbo	34
7	Resultados para GPT-4o	34

Índice de tablas

1	Reuniones	13
2	Investigación sobre el funcionamiento de los LLMs	14
3	Langchain y abstracción de LLMs	14
4	Técnicas de RAG	15
5	Ontologías, knowledge graphs y embeddings	15
6	Pipelines de RAG	15
7	Creación de nuevo Dataset	16
8	Definición de distintos escenarios	16
9	Nuevo benchmark	17
10	Recogida de resultados	17
11	Redacción de la memoria	17
12	Creación de anexos	18
13	Baja por enfermedad	20
14	Problemas técnicos	20
15	Falta de motivación	21
16	Mala acotación del alcance	21

Abreviaturas

API Application Programming Interface

JQL Jira Query Language

LLM Large Language Model

RAG Retrieval Augmented Generation

PLN Procesamiento del Lenguaje Natural

1. Introducción

Introducción.

2. Contexto

Este trabajo de fin de grado responde a las necesidades de la empresa LKS Next-GobTech, una empresa de desarrollo de software con enfoque en la innovación. De cara a comprender los motivos por los que esta empresa requiere de lo estudiado en este trabajo, se han de poner en contexto las herramientas y metodologías que utilizan para mejorar la calidad del producto que desarrollan. Partiendo del TFG de un compañero de escuela, Joel García Escribano [1], que consiste en un asistente conversacional que genera consultas JQL a partir de preguntas hechas con lenguaje natural, se ha estudiado la posibilidad de añadir una arquitectura de RAG (Retieval Augmented Generation) para aumentar la precisión de las respuestas que ofrece.

A continuación, se detallan las herramientas y metodologías que utiliza LKS Next-GobTech para la gestión de proyectos y se introduce la herramienta JiraGPTNext, que es el objeto de estudio de este trabajo.

2.1. Gestión de proyectos

La gestión de proyectos es el conjunto de metodologías utilizadas para coordinar la organización, la motivación y el control de recursos con el fin de alcanzar un objetivo. En el caso del desarrollo de software, ha sido un tópico controversial y de relevancia durante su historia, según la conocida ley de Brooks, expuesta en su libro *The mythical man-month* [2], añadir desarrolladores a un proyecto que va detrás del plazo solo hará que se retrase. Dentro de LKS Next-GobTech, donde se coordinan varios proyectos a la vez, resulta crucial una buena organización y división del trabajo en grupos preestablecidos al inicio de estos, con el fin de llevar un óptimo desarrollo en el que se cumplan los plazos establecidos.

En vistas de lo expuesto, parece obvia la necesidad de una herramienta de software capaz de suplir las necesidades implícitas en el desarrollo de software, por lo que dentro de esta empresa, se utiliza una herramienta de software llamada *JIRA*.

2.2. Herramientas

2.2.1. JIRA

JIRA es una herramienta de software propietario desarrollada por Atlassian para coordinar proyectos basados en tareas, llamadas incidencias dentro de la jerga de la aplicación. Esta herramienta sirve tanto para uso interno, como para que acceda el cliente, pudiendo encontrar un punto centralizado donde compartir información sobre el progreso y el estado del proyecto.

Las incidencias son la división atómica de paquetes de trabajo, que representan una tarea cuantificable asignable a un desarrollador y que ayudan a medir el desarrollo llevado a cabo. Al disponer de estados para las incidencias, se puede consultar de manera sencilla cómo progresa el proyecto.

Dentro de estas se pueden registrar distintos datos, como el tiempo que se prevé que va a tomar la tarea y el tiempo real que toma, mediante registros de trabajo, medidos en horas. Asimismo, se puede incluir información de interés para quien vaya a ser asignado el desarrollo de la incidencia, como una descripción, un resumen o enlaces externos a documentación relevante.

En un proyecto JIRA gestionado en LKS Next-GobTech se gestiona un flujo para las incidencias detallado a continuación: el desarrollador que la realice marcará la incidencia como hecha, a lo que un desarrollador senior validará el trabajo realizado y decidirá si es correcto o si ha de ser mejorado. Una vez confirmado, se marcará como validada y podrá pasar a la vista del cliente, que podrá comprobar el trabajo realizado.

2.2.2. Git - Gitlab

Al igual que se necesita controlar el estado de trabajos en el proyecto, también es necesario llevar un control de versiones para un óptimo desarrollo de software. En el caso de LKS Next-GobTech se utiliza Git [3] como herramienta y Gitlab como punto centralizado donde guardar los repositorios.

Gitlab es una plataforma que permite gestionar las versiones del software y la colaboración entre desarrolladores. De esta manera, se crea un repositorio para cada proyecto que tiene la empresa y para cada uno de estos repositorios se otorgan permisos de modificación a los desarrolladores que vayan a trabajar en ese proyecto.

Además, se utiliza la integración de JIRA con Gitlab para relacionar las incidencias con cambios realizados en el repositorio asignado al proyecto, de manera que tanto la confirmación del trabajo realizado como del tiempo invertido pueden ser contrastados.

2.3. JiraGPT Next

Partiendo del trabajo realizado por Joel García, se dispone de JiraGPT Next como una herramienta que ayuda a recuperar incidencias filtradas utilizando lenguaje natural. De esta manera, una persona que no posea conocimiento técnico en la generación de consultas JQL podrá filtrar incidencias fácilmente.

Tras esta herramienta se encuentra una llamada de API a un LLM que, utilizando

una plantilla para guiar al modelo, pedirá que se traduzca la pregunta en lenguaje natural a una consulta JQL que responda a lo que se pide.

La idea de este nuevo trabajo es realizar un estudio del potencial cambio en precisión que se puede lograr utilizando técnicas de Retrieval Augmented Generation (RAG), entendiendo precisión como el número de preguntas que el sistema es capaz de responder correctamente. Para ello, se van a proponer tres implementaciones diferentes de una base de conocimiento de la que el modelo pueda aprovechar la información contenida para generar respuestas partiendo de un mayor contexto.

Para estas tres propuestas, se ha hecho un estudio del estado del arte y se han consultado varios artículos que tratan de realizar mejoras similares a las expuestas en este trabajo, logrando inspiración en ellos.

3. Planificación

En esta sección se detallará la planificación del trabajo de fin de grado, en la que se incluirán los objetivos, la metodología y el cronograma de trabajo. Además, se incluyen los recursos necesarios para llevar a cabo el proyecto.

3.1. Tareas

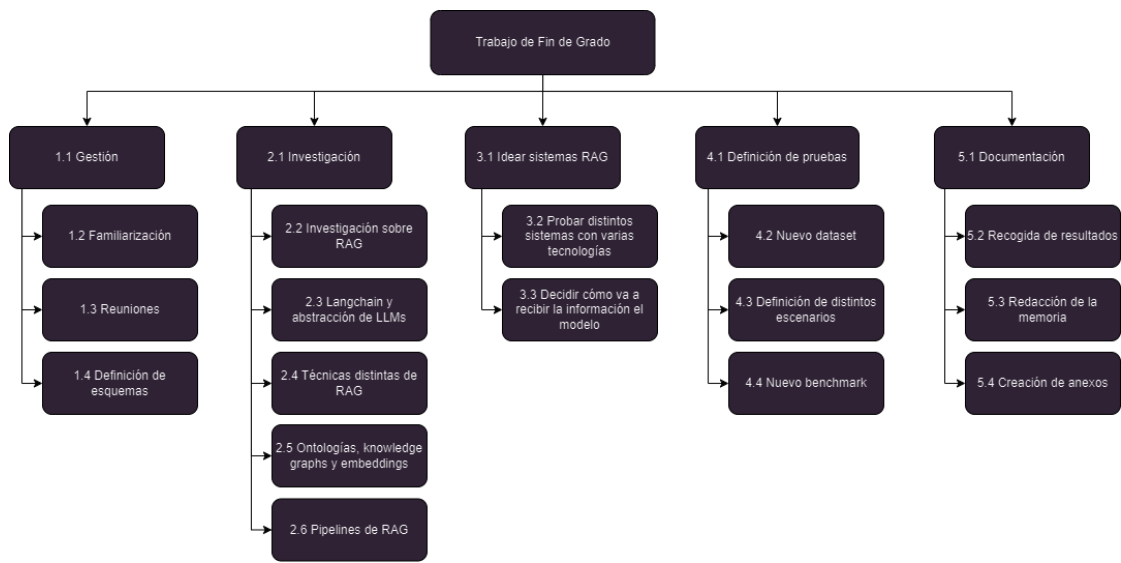


Figura 1: Esquema de división del trabajo

3.1.1. Gestión y planificación

En esta subsección se detallan las tareas llevadas a cabo con el fin de tener una buena gestión y planificación del proyecto.

Reuniones
Paquete de trabajo: Gestión
Tiempo estimado: 15 horas
Descripción: Se realizaron reuniones semanales tanto con Mikel Egaña, como con Arkaitz Carbajo, además, con Unai López se hicieron también reuniones más extensas para revisar el estado del proyecto.
Entregables: Actas de reuniones
Recursos: Microsoft Teams en las reuniones telemáticas y OneNote para la toma de notas.

Tabla 1: Reuniones

3.1.2. Investigación

Esta sección del proyecto ha sido la que más tiempo ha tomado, ya que se dedicó mucho tiempo al principio a investigar sobre el estado del arte y las tecnologías a utilizar. Además, durante la fase de desarrollo también se han realizado investigaciones para mejorar el modelo.

Investigación sobre el funcionamiento de los LLMs
Paquete de trabajo: Investigación
Tiempo estimado: 20 horas
Descripción: Se investigó sobre el funcionamiento de los LLMs, cómo se entrenan y cómo se utilizan. Además, se investigó sobre los diferentes modelos de LLMs y cuál sería el más adecuado para el proyecto.
Entregables: Notas sobre el funcionamiento de los LLMs
Recursos: OneNote para la toma de notas

Tabla 2: Investigación sobre el funcionamiento de los LLMs

Langchain y abstracción de LLMs
Paquete de trabajo: Investigación
Tiempo estimado: 20 horas
Descripción: Durante este paquete de trabajo se consultó un curso sobre RAG y Langchain, que se utilizó de base para implementar los sistemas de RAG que se evalúan en este trabajo.
Entregables: Notas sobre Langchain y abstracción de LLMs
Recursos: ChatGPT and LangChain: The Complete Developer's Masterclass [4]

Tabla 3: Langchain y abstracción de LLMs

Técnicas de RAG
Paquete de trabajo: Investigación
Tiempo estimado: 20 horas
Descripción: Se investigó sobre el estado del arte de sistemas de RAG y sobre cómo son utilizados en la actualidad. Además, se investigaron técnicas de recuperación de información con distintas bases de conocimiento.
Entregables: Notas sobre técnicas de RAG
Recursos: OneNote para la toma de notas

Tabla 4: Técnicas de RAG

Ontologías, knowledge graphs y embeddings
Paquete de trabajo: Investigación
Tiempo estimado: 30 horas
Descripción: Se investigó sobre ontologías y knowledge graphs, que se consultaron también en las reuniones con Mikel Egaña. Además, se investigaron embeddings y se hicieron pruebas para determinar qué información era útil para recuperar de una base de datos vectorial. Además, se probaron distintas bases de datos vectoriales.
Entregables: Notas sobre ontologías, knowledge graphs y embeddings. Decisión en base de datos vectorial.
Recursos: OneNote para la toma de notas. Visual Studio Code para la programación

Tabla 5: Ontologías, knowledge graphs y embeddings

Pipelines de RAG
Paquete de trabajo: Investigación
Tiempo estimado: 20 horas
Descripción: Se investigó sobre creación de pipelines con RAG, recuperando información de una base de conocimiento para mayor precisión generando JQL. Se probó a introducir en el benchmark el pipeline.
Entregables: Notas sobre RAG. Código con distintas pruebas.
Recursos: OneNote para la toma de notas. Visual Studio Code para la programación

Tabla 6: Pipelines de RAG

3.1.3. Ideas sistemas RAG

3.1.4. Definición de pruebas

Durante esta sección se definieron las pruebas que se iban a realizar para evaluar la calidad de cada una de las alternativas. Se ideó un nuevo conjunto de datos y se modificó el código del benchmark para ajustarlo al pipeline de RAG y permitir que sea replicable.

Creación de nuevo Dataset
Paquete de trabajo: Definición de pruebas
Tiempo estimado: 2 horas
Descripción: Se creó un nuevo conjunto de datos con 100 preguntas, que se utilizó para evaluar las distintas alternativas propuestas. Además, se utilizó un dataset existente en Hugging Face [5] para complementar el conjunto de datos.
Entregables: Nuevo conjunto de datos, archivo CSV.
Recursos: Visual Studio Code para la programación

Tabla 7: Creación de nuevo Dataset

Definición de distintos escenarios
Paquete de trabajo: Definición de pruebas
Tiempo estimado: 5 horas
Descripción: Se definieron distintos escenarios para evaluar las distintas alternativas propuestas. Se evaluó cómo debería ser el entorno de pruebas de Jira sobre el que se debería trabajar, con intención de aproximar el estudio a la realidad en una empresa. Se definieron los criterios de evaluación y se crearon las pruebas para cada uno de los escenarios.
Entregables: Ninguno
Recursos: Visual Studio Code para la programación

Tabla 8: Definición de distintos escenarios

Nuevo benchmark
Paquete de trabajo: Definición de pruebas
Tiempo estimado: 5 horas
Descripción: Se modificó el código del benchmark para ajustarlo al pipeline de RAG y permitir que sea replicable. Se añadieron las pruebas con el nuevo conjunto de datos y se realizaron pruebas con el nuevo conjunto de datos.
Entregables: Código modificado del benchmark
Recursos: Visual Studio Code para la programación

Tabla 9: Nuevo benchmark

3.1.5. Documentación

Esta sección describe cómo se realizó el proceso de documentación, tras la revisión de notas tomadas a lo largo del proyecto y la consulta con los tutores.

Recogida de resultados
Paquete de trabajo: Documentación
Tiempo estimado: 10 horas
Descripción: Se lanzan los distintos escenarios definidos y se recogen los resultados de las pruebas realizadas.
Entregables: Resultados de las pruebas
Recursos: Visual Studio Code para la programación

Tabla 10: Recogida de resultados

Redacción de la memoria
Paquete de trabajo: Documentación
Tiempo estimado: 50 horas
Descripción: Teniendo en cuenta la toma de notas a lo largo de todo el proyecto, la valoración de distintas aproximaciones y la consulta con tutores, se redactó la memoria acorde a lo que se había planeado al principio del proyecto
Entregables: Memoria del trabajo de fin de grado.
Recursos: Visual Studio Code para la redacción de la memoria. Compilador LaTeX.

Tabla 11: Redacción de la memoria

Creación de anexos
Paquete de trabajo: Documentación
Tiempo estimado: 5 horas
Descripción: Se crearon los anexos de la memoria, que incluyen el código del benchmark y los resultados de las pruebas realizadas.
Entregables: Anexos de la memoria.
Recursos: Visual Studio Code para la redacción de la memoria. Compilador LaTeX.

Tabla 12: Creación de anexos

3.2. Presupuesto

A lo largo de esta subsección se detalla el presupuesto necesario para el estudio transcurrido en este trabajo de fin de grado. Se incluyen los costes de los recursos humanos, los costes de los recursos materiales y los costes de los recursos software. El proyecto ha tenido una duración de 4 meses, por lo que se ha calculado el coste total en base a este periodo de tiempo.

3.2.1. Costes de software

El estudio de este trabajo se ha realizado con herramientas de software de código abierto en la medida de lo posible, si bien también se ha hecho uso de llamadas de API de OpenAI.

Como editores de código y ontologías, se han utilizado Visual Studio Code y Pro-tégé respectivamente, ambos de código abierto y gratuitos. Para la gestión de versiones se ha utilizado Git, también de código abierto y gratuito.

Durante las 2 primeras semanas del proyecto se realizó un curso de Udemy sobre ChatGPT and LangChain, que tuvo un coste de 14,99€ ¹.

3.2.2. Costes de mano de obra

Los costes de mano de obra se han calculado en base a las horas de trabajo invertidas en el proyecto y el salario medio de un ingeniero informático en España,

¹<https://www.udemy.com/course/chatgpt-and-langchain-the-complete-developers-masterclass/>

además del coste de dos profesores adjuntos de la Universidad del País Vasco y un tutor de la empresa LKS Next-GobTech. En el caso del ingeniero informático, se asume un rol de programador junior, con un salario medio de 21000€ brutos anuales. En el caso del profesor adjunto, según la página de la UPV/EHU, el salario medio es de 34144€ brutos anuales ².

Descontando impuestos y retenciones de los sueldos brutos para el programador junior, 12,20 % de IRPF: $21000 \times \frac{12,20}{100} \approx 2562\text{€}$ y la aportación de 1333€ a la Seguridad Social, resultaría en un salario neto de 17105€ netos al año.

$$\text{Coste total programador junior: } \frac{17105}{12 \text{ meses}} \times 4 \approx 5701\text{€}$$

Para el tutor de empresa se ha estimado el salario para un ingeniero informático manager de proyectos, con un salario medio de 42000€ brutos anuales [6]. Descontando una aportación de IRPF de 20,14 %: $42000 \times \frac{20,14}{100} \approx 8463\text{€}$ y una aportación de 2667€ a la Seguridad Social, resultaría en un salario neto de 30872€ netos al año. Con el tutor de empresa se ha estado 3 meses de los 4 de duración.

$$\text{Coste total tutor de empresa: } \frac{30872}{12 \text{ meses}} \times 3 \text{ meses} \approx 7718\text{€}$$

En cuanto a los tutores de la universidad, se ha asumido un salario de 34144€ brutos anuales, descontando impuestos y retenciones, 12,20 % de IRPF: $34144 \times \frac{12,20}{100} \approx 4165\text{€}$ y la aportación de 2168€ a la Seguridad Social, resultaría en un salario neto de 25872€ netos al año. Los tutores han estado disponibles un total de 15 horas al mes para el proyecto.

$$\begin{aligned} &\text{Coste total tutores de la universidad:} \\ &\frac{25872}{12 \text{ meses}} \times \frac{15 \text{ horas}}{176 \text{ horas/mes}} \times 4 \text{ meses} \times 2 \text{ tutores} \approx 1470\text{€}. \end{aligned}$$

El coste total de la mano de obra sería la suma de los costes de los tres roles, resultando en 14889€.

3.2.3. Costes de hardware

Para la realización de este trabajo se han utilizado tanto un portátil Lenovo Thinkpad T14, durante la estancia en LKS Next-GobTech, valorado en 1000€, como un ordenador de sobremesa montado por partes, con los siguientes componentes:

- Procesador: AMD Ryzen 7 7800X3D
- Tarjeta gráfica: NVIDIA GeForce RTX 2080 Super 8GB VRAM
- Memoria RAM: 32 GB DDR5

Valorado, en el momento de compra, en 1500€.

²<https://www.ehu.eus/es/web/gardentasun-ataria/ordainketak>

La amortización de estos dos equipos se puede calcular en un periodo de 10 años, ya que ambos equipos tienen una vida útil de al menos 10 años a día de hoy al ser equipos de alta gama.

La suma de ambos equipos es de 2500€. Por lo tanto, el coste para un proyecto de 4 meses es el siguiente:

$$\text{Coste total hardware: } \frac{2500}{10 \text{ años}} \times \frac{4 \text{ meses}}{12 \text{ meses}} \approx 83,33\text{€}$$

3.3. Gestión de riesgos

Durante la realización de un proyecto se han de tener en cuenta los posibles riesgos que puedan surgir, por lo que es necesario un plan de gestión de riesgos, donde se detalla la prevención y mitigación de los mismos. En esta subsección se detallan los riesgos que se han identificado y cómo se han gestionado.

Baja por enfermedad
Riesgo: Baja por enfermedad del alumno.
Probabilidad: Baja
Impacto: Alto
Prevención: El alumno se asegurará de llevar una vida saludable y de no excederse en el trabajo para evitar enfermedades.
Mitigación: En caso de enfermedad, se intentará seguir trabajando en la medida de lo posible y se pedirá ayuda a los tutores.

Tabla 13: Baja por enfermedad

Problemas técnicos
Descripción: Problemas técnicos con el hardware o software, ya sea un mal funcionamiento o la total incapacidad de uso.
Probabilidad: Media
Impacto: Medio
Prevención: Se realizarán copias de seguridad periódicas y se mantendrán actualizados los sistemas.
Mitigación: En caso de problemas técnicos, se intentará solucionar el problema lo antes posible y se pedirá ayuda a los tutores, se puede continuar trabajando en el otro equipo en caso de que uno falle.

Tabla 14: Problemas técnicos

Falta de motivación
Descripción: Falta de motivación para continuar con el proyecto, dejando el trabajo a medias y aplazando lo planeado.
Probabilidad: Baja
Impacto: Muy alto
Prevención: Se realizarán reuniones semanales con los tutores para mantener la motivación y el interés en el proyecto.
Mitigación: En caso de falta de motivación, se intentará buscar nuevas formas de motivación y se pedirá ayuda a los tutores.

Tabla 15: Falta de motivación

Mala acotación del alcance
Descripción: Mala acotación del alcance del proyecto durante la planificación, lo que puede llevar a un desbordamiento de las tareas y a un retraso en la entrega.
Probabilidad: Media
Impacto: Alto
Prevención: Se realizarán reuniones semanales con los tutores para revisar el alcance del proyecto y se mantendrá actualizado el plan de trabajo.
Mitigación: En caso de mala acotación del alcance, se intentará redefinir el alcance del proyecto y se pedirá ayuda a los tutores.

Tabla 16: Mala acotación del alcance

4. Tecnologías

A continuación se detallarán las distintas tecnologías que serán estudiadas durante este TFG. Cabe recalcar que varias de estas distintas tecnologías propuestas, como los grafos de conocimiento o las ontologías, han requerido de un estudio previo para poder ser implementadas en el proyecto.

Independientemente de los resultados que se obtengan con cada una de ellas, es necesario tener en cuenta el proceso de familiarización con las mismas, así como el tiempo invertido en su estudio y posterior implementación para un desempeño óptimo.

4.1. Modelos grandes de lenguaje

Dentro del campo de la inteligencia artificial y el Procesamiento del Lenguaje Natural (PLN), los modelos grandes de lenguaje, conocidos en inglés como Large Language Model (LLM) han sido una de las tecnologías más revolucionarias de los últimos años. Estos modelos son capaces de aprender de grandes cantidades de texto y generar texto de manera coherente y con sentido, pudiendo así responder a preguntas basándose en el contexto proporcionado.

Los LLMs se basan en arquitecturas de redes neuronales profundas, como los *transformers* [7], que permiten procesar secuencias de texto de manera más eficiente. Gracias a su mecanismo de atención, el cual permite al modelo enfocarse en las partes más relevantes de la secuencia de texto, los transformers han sido la base de muchos de los modelos de lenguaje más grandes y potentes de la actualidad.

A diferencia de modelos lingüísticos anteriores, los LLMs son capaces de aprender de manera no supervisada, lo que les permite obtener información de grandes cantidades de texto sin necesidad de etiquetas. Esto ha permitido el desarrollo de modelos masivos, como GPT-3 [8], que han demostrado ser capaces de realizar tareas de generación de texto, traducción, resumen, entre otras, con resultados sorprendentes.

4.2. Retrieval Augmented Generation

Se conoce como Retrieval Augmented Generation (RAG) a la arquitectura que combina la recuperación de información con la generación de texto. Esta arquitectura se compone de dos partes principales: un modelo de recuperación y un modelo de generación. El modelo de recuperación se encarga de recuperar información relevante de una base de conocimiento, mientras que el modelo de generación se encarga de generar texto basado en la información recuperada.

Esta arquitectura es especialmente útil cuando se trabaja con modelos de lenguaje grandes, ya que mejora el problema de las alucinaciones. En lugar de generar respuestas en base al conocimiento del que disponen durante el entrenamiento, que puede dar resultados erróneos, el modelo puede acceder a bases de conocimiento factual con las que puede generar respuestas más precisas y acordes al contexto.

4.2.1. Funcionamiento

El funcionamiento típico de esta arquitectura consta de un flujo dividido en dos partes principales, la recuperación de contexto y la generación de respuestas, que se explicarán brevemente a continuación:

Durante la recuperación de contexto se consulta en una base de conocimiento, que podría ser una base de datos vectorial, un grafo de conocimiento o una ontología, entre otros. Para hacer una consulta, se ha de contrastar la pregunta que un usuario haga con la información contenida, para obtener la información más relevante posible. Esta tarea requiere gran atención ya que es crucial de cara al desempeño que vaya a lograr el sistema.

Una vez se ha recuperado la información, se pasa a la generación de respuestas. En esta etapa, se utiliza la información recuperada junto con la pregunta inicial para guiar al modelo de lenguaje en la generación de respuestas. De esta manera, el modelo puede generar respuestas más precisas y acordes al contexto proporcionado.

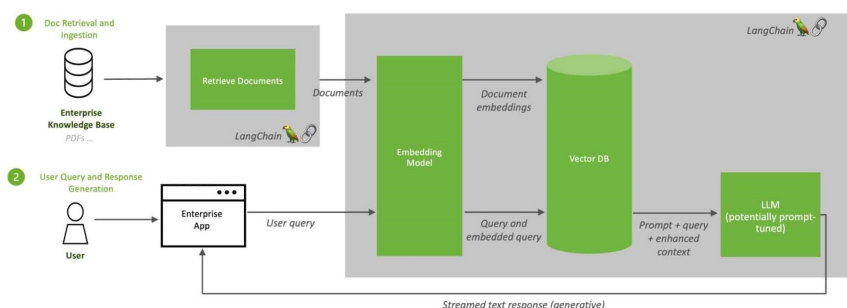


Figura 2: Esquema de funcionamiento de una arquitectura RAG [9]

4.3. Word embeddings

Los word embeddings, o simplemente embeddings, son una representación de palabras en un espacio multidimensional y son una técnica fundamental dentro del campo del PLN. Consiste en la transformación de palabras en vectores de números reales dentro del espacio, de manera que se puedan realizar operaciones matemáticas con ellas.

Para transformar las palabras en vectores se busca capturar la semántica de las palabras, de manera que palabras similares tengan vectores cercanos. Los métodos tradicionales de embeddings, como *word2vec* [10] o *GloVe* [11], utilizan modelos de aprendizaje no supervisado para aprender la representación de las palabras a partir de grandes cantidades de texto.

Los embeddings tienen muchas aplicaciones, como la clasificación de texto, la traducción automática o la recuperación de información, además, son una técnica que a día de hoy se sigue estudiando y mejorando.

4.4. Ontologías

Una ontología en el campo de la informática es una especificación formal y explícita de una conceptualización. En otros términos, una ontología es una representación de un conjunto de conceptos dentro de un dominio y las relaciones entre esos conceptos.

La utilidad de las ontologías radica en que permiten a los sistemas de información compartir conocimiento de manera más eficiente, ya que proporcionan una estructura común y unificada para la representación de los datos. Además, las ontologías permiten la interoperabilidad entre sistemas, ya que facilitan la comunicación entre ellos al tener una representación común del conocimiento. A día de hoy, son objeto de estudio en combinación con los modelos de lenguaje, explorando la posibilidad de mejorar la interpretación de los datos y la generación de consultas.

El lenguaje usado para definir ontologías es el *Web Ontology Language* (OWL), que es un lenguaje de marcado semántico para publicar y compartir ontologías en la web. OWL es desarrollado por el *World Wide Web Consortium* (W3C) y es una extensión de *Resource Description Framework* (RDF), que es un modelo de datos basado en grafos para describir recursos web.

4.5. Grafos de conocimiento

Los grafos de conocimiento, conocidos más comúnmente como *knowledge graphs* en inglés, son estructuras de datos que representan información de manera semántica. Estos grafos se componen de nodos y aristas, donde los nodos representan entidades y las aristas representan relaciones entre estas entidades. Los grafos de conocimiento son especialmente útiles para representar información estructurada y para realizar consultas complejas sobre esta información.

Los grafos de conocimiento se popularizaron con la creación de *Google Knowledge Graph* en 2012, un servicio de Google que proporciona información adicional en los resultados de búsqueda. Este servicio se basa en un grafo de conocimiento que

contiene información sobre una gran cantidad de entidades y relaciones entre estas entidades. Desde entonces, los grafos de conocimiento han sido utilizados en una gran variedad de aplicaciones, como la búsqueda semántica, las redes sociales y la recomendación de contenido.

A día de hoy, existen dos modelos de grafo de conocimiento más populares: *Resource Description Framework* (RDF) y *Property Graph Model*. El modelo RDF es un modelo de grafo de conocimiento basado en la web que se utiliza para representar información semántica en la web. En este tipo de grafo, los nodos representan recursos atómicos y las aristas representan relaciones entre estos, además, estos grafos son dirigidos, en este tipo de grafos la unidad de discurso se considera la unión de dos nodos por una relación. Por otro lado, el modelo de *Property Graph* es un modelo de grafo de conocimiento que tiende a usar nodos como objetos de un dominio, como tipos de datos ricos, donde estos mismos pueden considerarse la unidad de discurso, como se explica en esta cuestión de Stack Overflow [12].

En el ámbito de la inteligencia artificial, los grafos de conocimiento son especialmente útiles para mejorar el rendimiento de los modelos de lenguaje. Al combinar la información de un grafo de conocimiento con la información de un modelo de lenguaje, se pueden generar respuestas más precisas y acordes al contexto. Esto es una ventaja sobre los *Embeddings* ya que proporcionan un mayor contexto y una mayor precisión en las respuestas generadas. Son especialmente útiles en contextos donde es relevante mucha información interrelacionada, como en ámbitos de salud o medicina, donde es realmente útil tener en cuenta toda la información disponible para dar una respuesta precisa.

5. Diseño

Durante esta sección se hablará del punto de partida del asistente JiraGPT Next y del diseño que se ha propuesto como mejora para la precisión de las consultas generadas. Se presentarán 3 alternativas utilizando arquitecturas RAG, que buscan dotar al modelo de información sobre la generación de consultas JQL.

5.1. Estado inicial

Para cualificar el estado inicial del modelo se ha de poner en contexto la técnica utilizada para evaluar la precisión: un *benchmark* de 70 preguntas en el que se relaciona cada una con las incidencias que deberían ser recuperadas por el modelo.

La manera en la que se evalúa es ejecutando el conjunto entero de preguntas y evaluando si el asistente ha recuperado exactamente las incidencias contenidas en el conjunto de datos. Esto se decidió de esta manera ya que puede darse el caso en el que diferentes consultas devuelvan las mismas incidencias, lo que se consideraría correcto, con tal de que esas incidencias respondan a la pregunta del usuario.

En el momento de inicio de este trabajo, el asistente JiraGPT Next oscilaba entre un 45 y un 50 % de precisión en la recuperación de incidencias. Este resultado es fruto de una investigación sobre *prompt engineering* realizada previamente por Joel García [1]. El objetivo entonces, es buscar nuevas maneras de mejorar la precisión ofrecida por el modelo.

5.2. Propuestas

Se propone utilizar arquitecturas RAG para mejorar la precisión, ofreciendo al modelo información sobre la generación de consultas Jira Query Language (JQL). La idea detrás de esto es que, al tener un modelo de recuperación que pueda acceder a una base de conocimiento, el modelo de generación pueda generar respuestas más precisas y acordes al contexto proporcionado. Además, se propone un nuevo conjunto de datos:

Si bien el conjunto de datos inicial era robusto, se ha propuesto un nuevo conjunto, de 100 preguntas, que busca, no solo tener más datos, sino hacerlos más diversos y cambiar en cierto modo las preguntas para cubrir el máximo número de casos posible. Este conjunto de datos se ha pensado durante el desarrollo y las diferentes pruebas lanzadas y también se ha usado como apoyo un dataset existente en *Hugging Face* [5].

A continuación, se describirán las distintas alternativas propuestas para mejorar la precisión del modelo JiraGPT Next.

5.2.1. Ontología

Durante el inicio de este trabajo se consultaron artículos como *Sequeda et al.* [13], que exploraban la posibilidad de utilizar ontologías en el prompt para mejorar la interpretación de los datos y la generación de consultas SQL, logrando resultados prometedores. Partiendo de esta idea, se propone entonces crear una ontología que represente las reglas que existen en las consultas JQL. La información que se pretende representar en la ontología se ha extraído directamente de la documentación oficial de JIRA, brindada por Atlassian, donde se detallan las reglas que se deben seguir para la creación de consultas JQL [14]. Esta ontología serviría para interpretar las reglas que hay que seguir al generar consultas JQL, además, consta de ejemplos en cada una de las clases definidas, que ayuda a comprender mejor el funcionamiento de las reglas.

La ontología se ha desarrollado siguiendo el estándar *Web Ontology Language* (OWL), que es un lenguaje de marcado semántico para publicar y compartir ontologías en la web. OWL es desarrollado por el *World Wide Web Consortium* (W3C) y es una extensión de *Resource Description Framework* (RDF).

Durante esta parte, se considera una ejecución del benchmark como *baseline* para comparar los resultados obtenidos con la ontología y sin ella. Esta primera ejecución se realizaría inyectando el archivo entero de la ontología en el prompt, de manera que el modelo pueda acceder a la información de la ontología y utilizarla para generar consultas más precisas. Esta aproximación podría presentar resultados que, a priori, parecieran prometedores. Sin embargo, de cara al coste de inyectar un prompt tan grande, no es viable en un entorno de producción. Por ello, se propone una recuperación de información de la ontología dado un campo relevante para la pregunta del usuario. El diagrama en la siguiente figura muestra cómo será la interacción entre el modelo y la ontología.



Figura 3: Diagrama de RAG con ontología

Si bien una ontología es una manera de representar un espacio de conocimiento,

la documentación de JIRA no presenta una estructura demasiado compleja que representar con la semántica de una ontología. Podría considerarse que, por ende, no es realmente necesario el uso de una ontología para representar las reglas de JQL. Sin embargo, tras lo realizado en este trabajo, no sería complicado utilizar otra ontología que reuniese información más compleja y permitiese explotar la semántica de la ontología para mejorar la generación de consultas JQL.

5.2.2. Embeddings

De igual manera que en el diseño de la ontología, se propone capturar en esta base de datos vectorial la documentación oficial de JIRA. Esta base de conocimiento prueba a guardar los embeddings de los diferentes descripciones dentro de la documentación. La información que se ha considerado relevante ha sido cada campo/operador/función y sus respectivos ejemplos. De esta manera, dada una pregunta se podrían obtener los embeddings de las palabras y compararlas con los embeddings de la base de datos, de manera que el modelo obtenga ejemplos de campos relevantes para la pregunta del usuario.

Para capturar toda la información de la documentación se ha diseñado un programa en Python que realiza técnicas de *web scraping* y recorre las entradas de la documentación extrayendo de las tablas los ejemplos. Una vez hecho esto, se guarda en un archivo de texto que será dividido en diferentes partes para ser procesado por el modelo de embeddings.

Teniendo la pregunta del usuario, se ha de traducir al inglés, ya que la documentación oficial está en inglés y dada una pregunta en castellano la recuperación de información de los embeddings no sería efectiva. Para traducir la pregunta, se utiliza GPT-4o y, dada la pregunta traducida, se hace una búsqueda en la base de datos vectorial, obteniendo los ejemplos más relevantes para la pregunta dada. Esta información se inyecta en el prompt para que el modelo pueda generar una respuesta más precisa. El diagrama en la siguiente figura muestra cómo será la interacción entre el modelo y la base de datos vectorial.

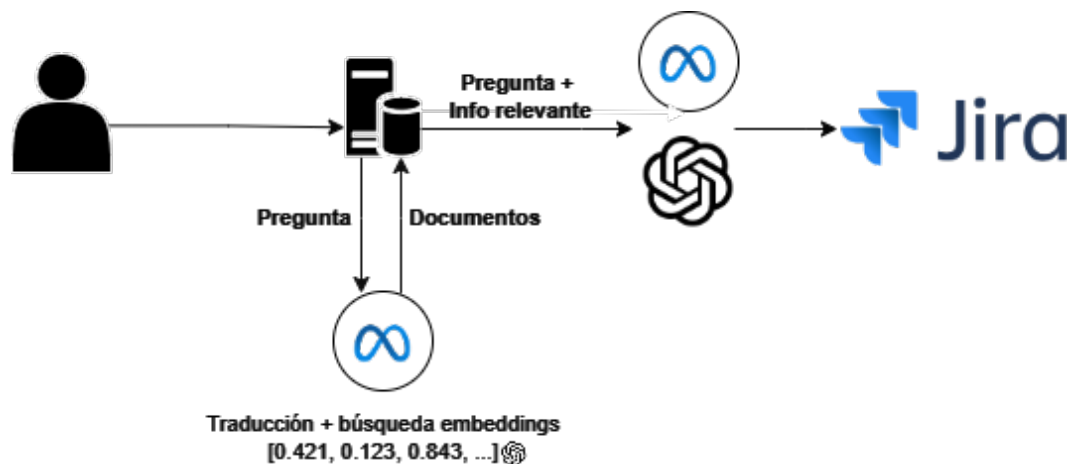


Figura 4: Diagrama de RAG con embeddings

5.2.3. Grafos de conocimiento

Como última propuesta para el trabajo, se ha planteado el uso de grafos de conocimiento para tratar de guiar al modelo en la estructura de la información contenida en la plataforma JIRA de LKS Next-GobTech. La idea detrás de esta propuesta es que, dada la información de Jira en forma de grafo, el modelo podría ser capaz de inferir cómo es la estructura de información de la plataforma Jira de LKS Next-GobTech y generar respuestas que sean más acordes a lo que se busca. Para esto, se ha de crear un grafo de conocimiento que contenga la información de Jira de cada proyecto que tenga activo LKS Next-GobTech, por lo que se ha de crear un programa que sea capaz de transformar esa información en un grafo y se pueda ejecutar de manera periódica, con el fin de que el grafo esté actualizado con la información real que se almacena en Jira.

El flujo sería el representado en la figura siguiente, donde se muestra cómo, dada una pregunta de un usuario, se extrae información del grafo de conocimiento que se inyectaría en el prompt para que el modelo pueda generar una respuesta con más contexto.

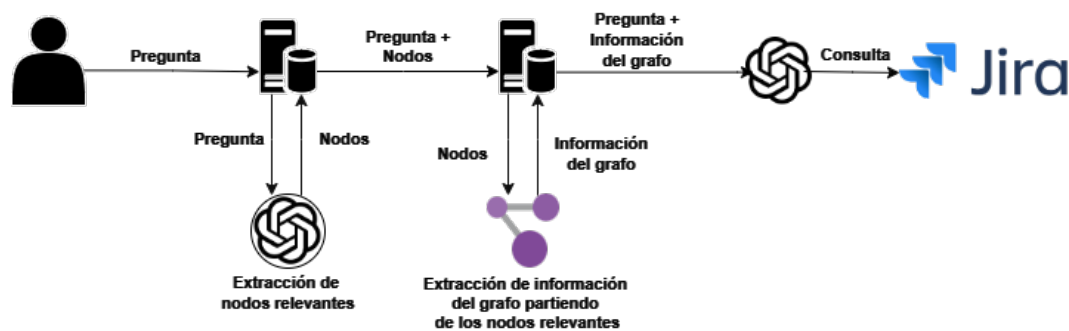


Figura 5: Diagrama de RAG con grafos de conocimiento

6. Implementación

A lo largo de esta sección se va a detallar la implementación de las distintas propuestas tecnológicas que se han descrito en el apartado anterior.

Para la implementación y el lanzamiento de muchas pruebas, se ha decidido ejecutar un LLM de manera local, ya que, de esta, manera, reducimos el coste de las llamadas a OpenAI a tan solo aquel que acarree el cálculo de los embeddings.

El modelo a utilizar será GPT-4o [15], al cual se harán llamadas a través de programas Python, utilizando la librería Langchain ³.

6.1. Implementación de RAG: Embeddings

Esta propuesta consta de una base de datos vectorial que contiene los embeddings de la documentación oficial de JIRA. Como software se ha optado por ChromaDB ⁴, una base de datos vectorial de código abierto que permite realizar búsquedas por similitud de vectores que, además, tiene una sencilla implementación con Langchain.

6.1.1. Extracción de datos

Para extraer los datos pertinentes de la documentación oficial de JIRA, se ha construido un *web scraper* que recorre la documentación oficial de JIRA en el lenguaje Python que extrae de las tablas para cada entrada título, descripción y ejemplos. Estos datos se almacenan en un archivo de texto que posteriormente será dividido en diferentes partes para ser procesado por el modelo de embeddings.

Como modelo de embeddings se han utilizado los embeddings de OpenAI, que mediante una llamada con texto devuelven el vector a almacenar en la base de datos. Todo esto con un programa en Python que utiliza Langchain para abstraer el uso de ChromaDB y de la API de OpenAI.

6.1.2. Interacción con el modelo

Cuando una pregunta es recibida en el sistema, esta será procesada por los embeddings de OpenAI, lo que genera un vector que se compara con los vectores almacenados en la base de datos vectorial. Los vectores más cercanos a la pregunta serán devueltos, conteniendo la información de Jira pertinente. Esta información se inyecta en el prompt para que el modelo pueda generar una respuesta más precisa.

³<https://www.langchain.com/>

⁴<https://www.trychroma.com/>

6.2. Implementación de RAG: Ontología

Como se ha mencionado en el apartado de diseño, se ha construido una ontología desde 0 utilizando la documentación oficial de JIRA para crear consultas JQL. Esta ontología describe los distintos tipos de operadores, campos y funciones que existen en este lenguaje de consulta. Además, se han añadido las relaciones entre estos elementos para que el modelo pueda inferir la información necesaria para responder a las preguntas. La idea detrás de esta ontología es modelar cómo funciona Jira Query Language, para que el modelo cometa menos errores de interpretación y pueda responder de manera más precisa. Se ha desarrollado tras el análisis de la documentación y la realización de consultas con el tutor para describir de manera correcta una ontología, siguiendo la semántica necesaria.

Esta ontología se ha desarrollado utilizando el software Protégé [16], gratuito y de código abierto, desarrollado por la universidad de Stanford. Una vez creada, se puede exportar como archivo RDF, para interactuar con ella desde fuera de Protégé.

6.2.1. Interacción con el modelo

La interacción posible de la ontología con el modelo parte desde la inyección del archivo RDF entero, como describe Sequeda et al. [13]. Sin embargo, esta aproximación no es viable en un entorno de producción, ya que inyectar un archivo tan grande en el prompt no es eficiente, pero se conserva de baseline.

Para obtener información relevante de la ontología se ha utilizado un LLM que extrae los campos relevantes dada una pregunta, que son expuestos anteriormente en el prompt, ya que son campos descritos en la ontología que no conoce el modelo. La respuesta del modelo serán los 3 campos más relevantes de entre todos los descritos en el prompt y desde los que se realizará una consulta a la ontología para obtener la información relevante de la misma.

Esta información obtenida consistirá en los campos, operadores, ejemplos, descripción y subclases (de existir) que serán inyectados en el prompt para que el modelo pueda generar una respuesta partiendo de un mayor contexto.

7. Ejecución de pruebas

Esta sección detallará todas las pruebas que se han realizado a las distintas propuestas de mejora del sistema. Primero se detallará el entorno de pruebas en el que han sido ejecutadas, con la intención de que sea reproducible, y posteriormente se comentarán los resultados obtenidos.

7.1. Entorno de pruebas

Las pruebas han sido realizadas en un entorno JIRA con un proyecto de prueba llamado GPT4, que contiene incidencias ficticias y sobre el proyecto Metaposta Firma Múltiple, un proyecto real de la empresa LKS Next-GobTech, que, en el momento de realización de las pruebas sigue en desarrollo y es actualizado diariamente. El modelo de lenguaje utilizado será GPT-4o, el más avanzado de OpenAI a fecha de realización del trabajo [15].

7.2. Evaluación de los resultados

En cuanto a los resultados, se utilizará el conjunto de 100 preguntas creado durante la realización del trabajo, que contiene una variedad de preguntas de distinta dificultad y con la intención de cubrir la mayor cantidad de casos posibles, se considerará correcta una respuesta si las incidencias devueltas por la API de Jira con la sentencia JQL generada por el modelo son exactamente las mismas que las esperadas, que serán obtenidas mediante otra llamada a la API de Jira con la sentencia JQL predefinida que corresponde a la pregunta.

Los resultados consistirán en una puntuación del 0 al 100, que indicará el número de preguntas respondidas de manera correcta, además, se intentará analizar el por qué de los fallos en las respuestas, si los hubiera, con la intención de mejorar el modelo de lenguaje a futuro.

7.3. Resultados

Los resultados obtenidos, evaluados tanto para GPT-4o como para GPT-3.5-turbo se muestran a continuación, en dos gráficas distintas, se muestra el estado inicial, que es la ejecución sin ningún sistema de RAG y las tres propuestas de mejora:

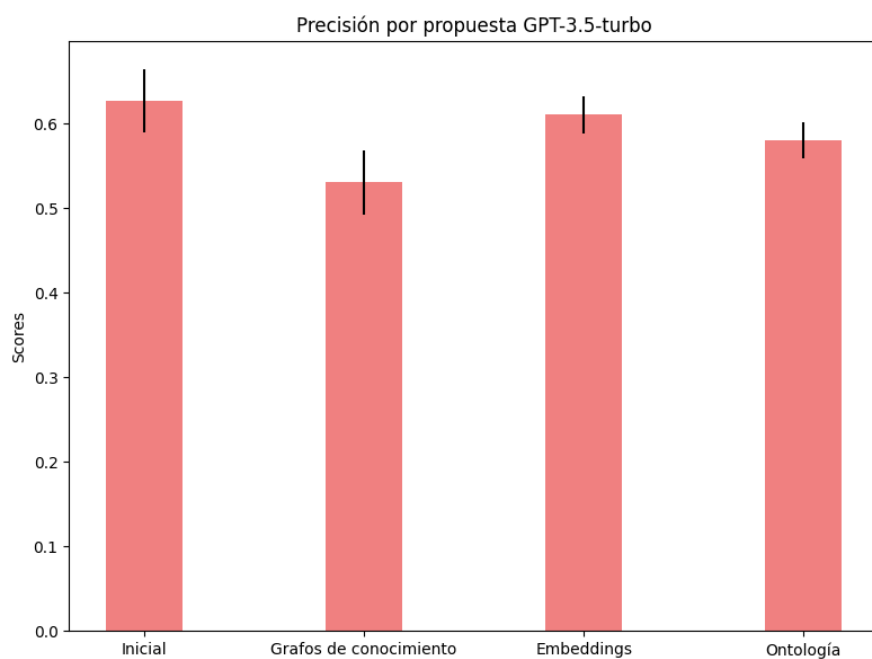


Figura 6: Resultados para GPT-3.5-turbo

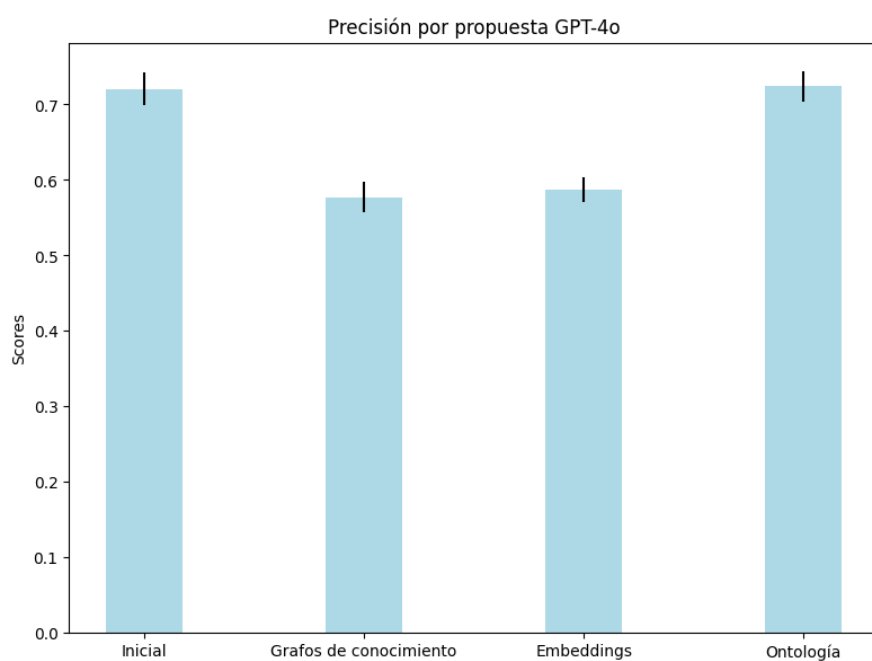


Figura 7: Resultados para GPT-4o

8. Conclusiones

8.1. Objetivos

El objetivo de este trabajo, desde el primer momento, ha sido estudiar cómo se puede aproximar un sistema de RAG para otorgar contexto a un modelo, con la intención de mejorar la precisión con la que genere consultas JQL, ya que los modelos de lenguaje actuales, no parecen poseer mucho contexto sobre la generación de consultas JQL, además, si no son conocedores de la estructura de los proyectos, no pueden generar ciertas consultas complejas que sean útiles para los usuarios.

8.2. Conclusiones personales

Este trabajo, aunque ha tenido sus altibajos, ha sido una experiencia que calificaría como altamente positiva. En un principio, la idea que se me planteó de adentrarme en un mundo que no conocía, como es el de los grafos de conocimiento o las ontologías, me pareció bastante llamativa por el simple hecho de que iba a aprender algo nuevo, además, juntándolo con el estado del arte de los modelos de lenguaje, parecía que iba a ser realmente enriquecedor, y así ha sido. Ha habido momentos de mayor frustración, donde parecía que la implementación de las diferentes propuestas estaba un poco "cogida con pinzas", pero la investigación es así, y es lo que la hace interesante. Si algo saco en claro de este trabajo, es que la investigación es un camino que no es sencillo, pero es muy satisfactorio y no podría estar más agradecido de haber hecho el trabajo con Arkaitz, Mikel y Unai, que me han ayudado en todo momento y que me han hecho apreciar lo que estaba haciendo.

8.3. Trabajo futuro

En cuanto al trabajo posible realizable en este proyecto, se podrían proponer distintas mejoras, como la creación de un grafo más complejo y con una mejor representación de la información o una ontología que cubriese de mejor manera los conceptos enteros de JIRA, no solo JQL, ya que este no parece contener tanta semántica como para que una ontología parezca realmente útil. Mencionar que, durante el transcurso del trabajo, se pidió un proyecto de Hazitek para obtener financiación y desarrollar el proyecto más allá de su estado actual, con una posible mejora subsecuente.

9. Anexo I

9.1. Conjunto de preguntas

Las 100 preguntas utilizadas para la evaluación de las distintas propuestas de mejora y la consulta JQL que se utiliza para evaluar las incidencias esperadas.

ID	Pregunta	Consulta JQL
1	Muestra las incidencias en progreso en GPT4	status = . ^{En} progreso.and project = GPT4
2	Muestra las incidencias en progreso y sus horas acumuladas en GPT4	status = . ^{En} progreso.and project = GPT4
3	Muestra las incidencias que ya estan entregadas a cliente en GPT4	status = . ^{Entregado} .and project = GPT4
4	Muestra las incidencias que se han pasado de horas y por cuánto en GPT4	workratio > 100 and project = GPT4
5	Muestra las incidencias que deberían acabar en agosto de 2023 en el proyecto GPT4	due >= "2023-08-01".AND due <= "2023-08-31"
6	Muestra las incidencias sin cerrar ni resolver en GPT4	status not in (Resuelto, Cerrado) and project = GPT4
7	Muestra quién tiene menos carga de trabajo en el proyecto GPT4	project = GPT4 ORDER BY assignee ASC, updated DESC
8	Muestra quién tiene menos carga de trabajo en GPT4	project = "GPT4"
9	Cuántos tickets se han resuelto en agosto de 2023 en el proyecto GPT4?	status changed to Resuelto DURING ('2023-08-01' , '2023-08-31')
10	Cuántos tickets se han resuelto en agosto de 2023 en GPT4 en el proyecto GPT4?	project = GPT4 AND status changed to Resuelto DURING ('2023-08-01' , '2023-08-31')
11	Muéstrame todas las incidencias abiertas asignadas a Alberto Aróstegui García en GPT4	project = GPT4 AND assignee = 'Alberto Aróstegui García' AND status = Abierto
12	Muéstrame todas las incidencias con estado Abierto asignadas a Alberto Aróstegui García en GPT4	project = GPT4 AND assignee = 'Alberto Aróstegui García' AND status = Abierto
13	¿Cuántos tickets sin resolver hay en el proyecto GPT4?	project = GPT4 AND status != Resuelto
Continúa en la siguiente página		

ID	Pregunta	Consulta JQL
14	Encuentra las incidencias asignadas a Alberto Aróstegui García en el proyecto GPT4.	project = GPT4 AND assignee = 'Alberto Aróstegui García'
15	¿Cuántas incidencias se cerraron en agosto de 2023?	status changed to Cerrado DURING ('2023-08-01', '2023-08-31')
16	¿En el proyecto GPT4 que incidencias fueron cerradas durante agosto de 2023?	project = GPT4 AND status changed to Cerrado DURING ('2023-08-01', '2023-08-31')
17	Muestra todas las incidencias con alta prioridad en el proyecto GPT4	priority = High and project = GPT4
18	Dame una lista de las incidencias cuyo estado cambio en agosto de 2023 en el proyecto GPT4.	status CHANGED DURING ('2023-08-01', '2023-08-31')
19	Encuentra todos los tickets con 'base de datos' en el resumen en el proyecto GPT4.	summary 'base de datos' and project = GPT4
20	¿Cuántos tickets están resueltos en el proyecto GPT4?	project = GPT4 AND status = Resuelto
21	Muestra todas las incidencias reportadas por Alberto Aróstegui García en el proyecto GPT4	reporter = 'Alberto Aróstegui García' and project = GPT4
22	Muestra el progreso de la incidencia con el campo personalizado Custom_Id con valor GPT4-30	Custom_Id GPT4-30 and project = GPT4
23	¿Cuáles son las incidencias creadas en agosto de 2023 en el proyecto GPT4?	project = GPT4 AND created >= "2023-08-01.^AND created <= 2023-08-31
24	¿Cuáles son las incidencias creadas en agosto de 2023 en el proyecto GPT4? Ordenalas de mayor a menor prioridad	project = GPT4 AND created >= "2023-08-01.^AND created <= "2023-08-31.^ORDER BY priority DESC
25	¿Cuántos bugs se han reportado en el proyecto GPT4?	issuetype = Bug and project = GPT4
26	Dame todas las incidencias en la fase de 'Resuelto' del proyecto GPT4.	project = GPT4 AND status = Resuelto"
27	Muéstrame todas las incidencias reabiertas en el proyecto GPT4	status = Reabierto and project = GPT4
28	Muéstrame todas las incidencias con estado Reabierto. ^{en} el proyecto GPT4	status = Reabierto and project = GPT4
Continúa en la siguiente página		

ID	Pregunta	Consulta JQL
29	Muestra todos los tickets que vencen en agosto de 2023 en el proyecto GPT4.	due >= "2023-08-01.^AND due <= "2023-08-31"
30	¿Qué tickets terminan después del 1 de septiembre de 2023 en el proyecto GPT4?	due > "2023-09-01.^and project = GPT4
31	Encuentra todas las incidencias movidas a 'Validado' en agosto de 2023 en el proyecto GPT4	status changed to Validado DURING ('2023-08-01', '2023-08-31')
32	Dame las incidencias resueltas en agosto de 2023 en el proyecto GPT4	status changed to Resuelto DURING ('2023-08-01', '2023-08-31')
33	¿Cuántos tickets están en fase de 'En Progreso' en el proyecto GPT4?	status = 'En progreso' and project = GPT4
34	Lista todos los tickets creados en agosto de 2023 en el proyecto GPT4	created >= "2023-08-01.^AND created <= "2023-08-31.^and project = GPT4
35	Muéstrame las incidencias abiertas más antiguas en el proyecto GPT4.	status = Abierto and project = GPT4 ORDER BY created ASC
36	Muéstrame las incidencias con estado Abierto"más antiguas en el proyecto GPT4."	status = .^abierto.^and project = GPT4 ORDER BY created ASC
37	Lista todos los tickets con la etiqueta 'seguridad' y dame un resumen en el proyecto GPT4.	labels = "seguridad.^and project = GPT4
38	¿Cuántas incidencias se han movido a 'En progreso' en agosto de 2023 en el proyecto GPT4?	project = GPT4 AND status changed to 'En progreso' DURING ('2023-08-01', '2023-08-31')
39	¿Cuáles son las incidencias de máxima prioridad asignadas a Alberto Aróstegui García en el proyecto GPT4?	project = GPT4 AND assignee = .^Alberto Aróstegui García.^AND priority = Highest
40	Lista todas las incidencias cerradas en agosto de 2023 en el proyecto GPT4	project = GPT4 AND status changed to Cerrado DURING ('2023-08-01', '2023-08-31')
41	¿Cuántas incidencias nuevas se han agregado al proyecto GPT4 en agosto de 2023?	project = GPT4 AND created >= "2023-08-01.^AND created <= "2023-08-31"
42	Encuentra todas las incidencias con 'rendimiento' en su descripción en el proyecto GPT4.	description rendimiento
Continúa en la siguiente página		

ID	Pregunta	Consulta JQL
43	Encuentra todos los tickets movidos a 'Cerrado' en agosto de 2023 en el proyecto GPT4.	status changed to Cerrado DURING ('2023-08-01', '2023-08-31')
44	Muestra todas las incidencias que están vencidas en el proyecto GPT4	due < now() and status != Cerrado and project = GPT4
45	Lista todos los tickets en los que alguien ha votado en el proyecto GPT4.	voter is not empty and project = GPT4
46	¿Cuántas incidencias están en la fase 'Abierto' en el proyecto GPT4?	project = GPT4 AND status = Abierto
47	¿Cuántas incidencias están abiertas en el proyecto GPT4?	project = GPT4 AND status = Abierto
48	Recupera las incidencias que tengan que ver con Gitlab en el proyecto GPT4	summary "Gitlab." OR description "Gitlab." and project = GPT4
49	Muestra las incidencias sin asignar en el proyecto GPT4	project = GPT4 AND assignee is EMPTY
50	Cuántas incidencias asignadas hay en el proyecto GPT4?	project = GPT4 AND assignee is not EMPTY
51	Muéstrame las incidencias abiertas en GPT4	status not in (Resuelto, Cerrado) and project = GPT4
52	Que incidencias de maxima prioridad en GPT4	project = GPT4 and priority = Highest
53	Selecciona las incidencias sin resolver de esta semana en GPT4	created >= startOfWeek() and status != Resuelto and project = GPT4
54	Muestra todas las incidencias con enlaces externos en GPT4	attachments is not EMPTY and project = GPT4
55	Selecciona las incidencias que vencen en los proximos 3 dias en GPT4	due <= endOfDay(-3d) and status != Resuelto and project = GPT4
56	Muestra las incidencias en las que se esta trabajando ahora mismo en GPT4	status = .En Progreso. and project = GPT4
57	Muestra las incidencias creadas esta semana en GPT4	project = GPT4 and created >= startOfWeek()
58	Muestra las incidencias creadas en los ultimos 7 dias en GPT4	created >= -7d() and project = GPT4
59	Muéstrame las incidencias que vencen el 11 de agosto de 2023 en GPT4	due = "2023-08-11"
Continúa en la siguiente página		

ID	Pregunta	Consulta JQL
60	Dame las incidencias del proyecto GPT4 que contengan etiquetas	project = GPT4 and labels is not EMPTY
61	Muestrame las incidencias asignadas a Alberto Aróstegui García que tengan etiquetas en GPT4	assignee = .^Alberto Aróstegui García.^and labels is not EMPTY AND project = GPT4
62	Dame las incidencias asignadas a mi en GPT4 que contengan enlaces externos	assignee = currentUser() and attachments is not EMPTY and project = GPT4
63	Dame las incidencias asignadas a mi en GPT4	assignee = currentUser() and project = GPT4
64	Muestrame las incidencias que estan en un sprint abierto	sprint in openSprints()
65	Que incidencias estan en un sprint ya cerrado	sprint in closedSprints()
66	¿Cuáles son los ítems que tienen una fecha de vencimiento entre el 1 de agosto de 2023 y el 31 de agosto de 2023 en GPT4?	due >= "2023-08-01.^AND due <= "2023-08-31.^and project = GPT4
67	¿En que proyectos ha votado al menos una persona?	voter is not EMPTY
68	¿Qué incidencias tengo yo asignadas en GPT4?	assignee = currentUser() and project = GPT4
69	¿Qué incidencias están resueltas ahora mismo en GPT4?	status = Resuelto and project = GPT4
70	¿Qué tickets se cerraron durante agosto de 2023?	status changed to Cerrado DURING ('2023-08-01', '2023-08-31')
71	¿Qué tickets cambiaron de estado durante agosto de 2023?	status changed DURING ('2023-08-01', '2023-08-31')
72	¿Qué incidencias fueron creadas el último mes en GPT4?	created >= startOfMonth(-1) and project = GPT4
73	¿Cuántas incidencias en el proyecto GPT4 están cerradas pero no resueltas?	status = Cerrado and status != Resuelto and project = GPT4
74	Muestrame las incidencias que se han movido a Resuelto en agosto de 2023	status changed to Resuelto DURING ('2023-08-01', '2023-08-31')
75	Dame las incidencias que han sido actualizadas en las ultimas 24 horas	updated >= -24h()
76	¿Que incidencias vencen hoy en MFM	due <= endOfDay() and project = MFM
Continúa en la siguiente página		

ID	Pregunta	Consulta JQL
77	Cuántas incidencias estan abiertas pero no asignadas?	status = Abierto and assignee is EMPTY
78	¿Qué incidencias fueron resueltas en los últimos 30 días en MFM?	status changed to Resuelto DURING ('-30d', now()) and project = MFM
79	¿Cuántas incidencias se han movido a 'En progreso' en los últimos 7 días en MFM?	status changed to 'En progreso' DURING ('-7d', now()) and project = MFM
80	¿Qué incidencias en MFM están en un sprint y no están asignadas?	sprint in openSprints() and assignee is EMPTY and project = MFM
81	¿Que incidencias tienen enlaces externos?	attachments is not EMPTY
82	Lista todas las incidencias que contengan la palabra 'urgente' en MFM	summary 'urgente' and project = MFM
83	Dame las incidencias de prioridad alta que todavia no estan asignadas	priority = High and assignee is EMPTY
84	Muestramen las incidencias cerradas el último trimestre en MFM	status changed to Cerrado DURING ('-3M', now()) and project = MFM
85	Dame las incidencias de baja prioridad que estan en progreso	priority = Low and status = 'En progreso'
86	¿Qué incidencias tienen un campo personalizado con valor 'GPT4-30'?	Custom_Id GPT4-30
87	¿Cuántas incidencias se han creado en los últimos 7 días en MFM?	created >= -7d() and project = MFM
88	Muestra las incidencias del proyecto MFM que están marcadas como críticas y aún están abiertas	priority = Highest and status = Abierto and project = MFM
89	Dame las incidencias que han cambiado de prioridad	priority CHANGED
90	¿Cuántas incidencias relacionadas con fallos hay en MFM?	issuetype = Bug and project = MFM
91	Dame el total de horas registradas en las incidencias tipo Epic de MFM	issuetype = Epic and project = MFM
92	¿Qué incidencias están Resueltas pero aun no se han cerrado?	status = Resuelto and status != Cerrado
93	¿Cuántas incidencias se han creado en el último mes en MFM?	created >= startOfMonth(-1) and project = MFM
Continúa en la siguiente página		

ID	Pregunta	Consulta JQL
94	Dame las incidencias que han sido actualizadas en las últimas 24 horas en MFM	updated >= -24h() and project = MFM
95	¿Qué incidencias están ahora mismo validadas en MFM?	status = Validado and project = MFM
96	¿Cuántas incidencias se han movido a 'En progreso' en los últimos 7 días en MFM?	status changed to 'En progreso' DURING ('-7d', now()) and project = MFM
97	¿Qué incidencias en MFM están en un sprint y no están asignadas?	sprint in openSprints() and assignee is EMPTY and project = MFM
98	¿Qué incidencias de baja prioridad están en progreso en MFM?	priority = Low and status = 'En progreso' and project = MFM
99	Dame las incidencias que han cambiado de prioridad en MFM	priority CHANGED and project = MFM
100	¿Cuántas incidencias relacionadas con fallos hay en GPT4?	issuetype = Bug and project = GPT4

Referencias

- [1] Joel García Escribano. «JiraGPT Next». En: (2023).
- [2] Frederick P. Brooks. *The mythical man-month – Essays on Software-Engineering*. Addison-Wesley, 1975.
- [3] Scott Chacon y Ben Straub. *Pro git*. Apress, 2014.
- [4] Stephen Grider. *ChatGPT and LangChain: The Complete Developer's Masterclass*. Accessed: During February 2024. URL: <https://www.udemy.com/course/chatgpt-and-langchain-the-complete-developers-masterclass/>.
- [5] @ManthanKulakarni. *Text2JQL*. Accessed: during March 2024. URL: https://huggingface.co/datasets/ManthanKulakarni/Text2JQL_v2.
- [6] Glassdoor. *Glassdoor*. Accessed: 2024-03-30. URL: https://www.glassdoor.es/Sueldos/it-project-manager-sueldo-SRCH_K00,18.htm.
- [7] Ashish Vaswani et al. «Attention is All you Need». En: *Advances in Neural Information Processing Systems*. Ed. por I. Guyon et al. Vol. 30. Curran Associates, Inc., 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.
- [8] Tom Brown et al. «Language Models are Few-Shot Learners». En: *Advances in Neural Information Processing Systems*. Ed. por H. Larochelle et al. Vol. 33. Curran Associates, Inc., 2020, págs. 1877-1901. URL: https://proceedings.neurips.cc/paper_files/paper/2020/file/1457c0d6bfc4967418bfb8ac14-Paper.pdf.
- [9] Rick Merritt. *What Is Retrieval-Augmented Generation, aka RAG?* Accessed: 2024-03-30. URL: <https://blogs.nvidia.com/blog/what-is-retrieval-augmented-generation/>.
- [10] Tomas Mikolov et al. *Efficient Estimation of Word Representations in Vector Space*. 2013. arXiv: [1301.3781](https://arxiv.org/abs/1301.3781) [cs.CL].
- [11] Jeffrey Pennington, Richard Socher y Christopher Manning. «GloVe: Global Vectors for Word Representation». En: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Ed. por Alessandro Moschitti, Bo Pang y Walter Daelemans. Doha, Qatar: Association for Computational Linguistics, oct. de 2014, págs. 1532-1543. DOI: [10.3115/v1/D14-1162](https://doi.org/10.3115/v1/D14-1162). URL: <https://aclanthology.org/D14-1162>.
- [12] @FrobberOfBits. *Graph databases vs triple stores*. Accessed: 2023-05-22. URL: <https://stackoverflow.com/questions/30166006/graph-databases-vs-triple-stores-when-to-use-which>.
- [13] Juan Sequeda, Dean Allemang y Bryon Jacob. *A Benchmark to Understand the Role of Knowledge Graphs on Large Language Model's Accuracy for*

- Question Answering on Enterprise SQL Databases*. 2023. arXiv: [2311.07509](https://arxiv.org/abs/2311.07509) [cs.AI].
- [14] Atlassian. *Use advanced search with Jira Query Language (JQL)*. Accessed: 2024-03-30. URL: <https://support.atlassian.com/jira-service-management-cloud/docs/use-advanced-search-with-jira-query-language-jql/>.
- [15] OpenAI. *GPT-4o*. Accessed: 2024-05-13. URL: <https://openai.com/index/hello-gpt-4o/>.
- [16] Stanford University. *Protégé*. Accessed: 2024-03-20. URL: <https://protege.stanford.edu/>.